AI Creator Agent Lab

AI 创作智能体策略与评测实验室

AGENT STRATEGY · CREATOR WORKFLOW
EVALUATION · PRODUCT OPERATIONS

我把「创作者的流程」翻译成「Agent 的行为」，再用可复现的测试证明它真的变好了。
这份作品集不是一个视频作品合集，而是**四个可以被追问的判断**：该做什么、怎么设计、怎么定义好坏、不达标时改哪里。

核心交付 · CORE DELIVERABLES

CreatorPilot 主项目 P.04–16

Agent Benchmark 评测 P.17–22

竞品与机会点 P.23–26

反馈驱动的迭代 P.27–29

Skill / Memory 机制 P.30–31

数据口径 · DATA PROVENANCE

实测 桌面推演 模拟

每一页的数据都标注来源。原型中的工具调用为演示实现，评测分数为**原型态基线**，不代表任何真实模型性能。

唐睿

2027 届 · 网络与新媒体 | 13410164607 | 2901941647@qq.com

不是「会用 AI 工具的人」，是能把创作流程拆成 Agent 行为的人。

剪映这类产品的难点早就不在「能不能生成」，而在「生成之后能不能改、改得对不对、下一次会不会更准」。 这个岗位要的是：能定义什么叫「做得好」，能设计出让模型做得到的流程，能用测试证明它变好了。

■ 用一句话说明我的差异

大多数 AI 创作作品展示的是**「生成结果」**。
我展示的是**「生成过程中的判断」**——
哪一步该让模型自己决定，哪一步必须停下来问人，哪一步失败之后还能退到哪。

■ 能力闭环 · CAPABILITY LOOP（每一步都有对应交付物）

01 / 发现问题

内容理解

从创作者真实流程里找断点，而不是从功能列表里找需求。

→ P.05–07

02 / 设计方案

任务规划

把一句自然语言编译成可执行、可检查、可中断的任务图。

→ P.08–16

03 / 定义好坏

效果验证

先写 Rubric，再看分数；先看失败模式，再谈能力上限。

→ P.17–22

04 / 推动变好

运营迭代

把反馈变成需求池，把需求变成可证伪的实验。

→ P.23–29

EVIDENCE 01

主项目：从 0 到可点的原型

13 页完整链路：3 类画像 → 痛点排序 → 能力架构 → 任务图 → 失败处理 → PRD → 路线图。原型中每一步的 Agent 行为都可点击验证。

EVIDENCE 02

评测：24 条任务 × 3 次重复

6 维 Rubric、双人独立评分、失败样例全留痕。结论不是「效果不错」，而是「可控性 3.2 / 5，是当前最短板」。

EVIDENCE 03

运营：50 条反馈 → 2 个实验

反馈不是统计出来的，是归因出来的。1 条「改开头把卖点删了」可以拆出 3 个产品问题、1 个实验、1 个回归用例。

A · Agent 机制理解

能把一个需求画成 DAG，说明每个节点的输入输出、验收条件、失败后的降级路径，以及哪些步骤必须停下来问人。

B · 效果定义

把「好」拆成 6 个可打分维度，写出 1–5 分锚点，设定通过线与否决项，让两个人独立打分能打出一致的结论。

C · 内容生产

写过脚本、拆过分镜、对过字幕、调过节奏；知道创作者在「第 4 次改开头」时最想摔电脑。

D · 数据与实验

从 50 条反馈到需求池再到实验方案，写得清样本量、护栏指标和「什么情况下承认假设错了」。

SEC A 主项目 · CreatorPilot｜面向短视频创作者的 AI Agent

从需求到可点原型，13 页完整链路 P.04–16

04 项目一页纸：问题 / 洞察 / 方案 / 证据
05 场景设定与任务卡
06 三类创作者画像与任务链路
07 痛点清单与需求优先级
08 产品定位与机会空位
09 Agent 能力架构（五层）
10 六阶段核心工作流
11 约束编译与任务图（Plan Schema）
12 工具调用契约与失败处理
13 人工确认与风险分级
14 可交互原型（附 prototype.html）
15 PRD 摘要与验收标准
16 版本路线图与成功指标
– 附件：benchmark-tasks.csv

SEC B Agent 效果评测

P.17–22

24 条任务 × 3 次重复 × 6 维 Rubric。用可追溯的记录证明：我会定义效果，也会读失败。

17 评测方法论
18 24 条标准化任务集
19 评分 Rubric 与通过线
20 实测结果与分维度得分
21 失败模式复盘（3 例）
22 结论与优化优先级

SEC C 竞品研究

P.23–26

3 款可实际体验的产品，同一组 5 个任务，记录操作步骤、耗时与断点，不只读宣传页。

23 体验方法与统一任务
24 八维能力矩阵
25 用户旅程与 5 个断点
26 面向剪映的 3 个机会点
– 证据：体验记录表

SEC D·E 迭代 & 机制

P.27–32

50 条标注为模拟的反馈 → 归因 → 需求池 → 2 个可证伪实验；再补 Skill 与 Memory 的机制设计。

27 50 条反馈数据集
28 归因分析与需求池
29 版本实验计划
30 Skill 设计说明
31 Memory 策略说明
32 产品判断与关于我

推荐阅读路径 · 10 MIN PATH

P.04 全貌 → P.10 流程 → P.14 原型 → P.20 结论 → P.22 改进

数据口径

- 实测：真实产品体验记录，标版本与日期
- 桌面推演：按固定规则模拟 Agent 决策
- 模拟：合成数据，不可当作用户结论

随附文件

- prototype.html
- benchmark-tasks.csv
- feedback-50.csv

这份作品集的边界 · WHAT THIS IS NOT

不含真实用户调研。3 类画像来自 12 篇创作者公开访谈与自身体验归纳，是定性假设，不是定量结论。

不含真实模型分数。Benchmark 在自建原型上按固定规则推演，用于验证评测流程本身可用，不作为模型能力结论。

不含已上线功能。CreatorPilot 是独立概念设计，与剪映现有功能没有对应承诺，机会点仅为建议。

PROJECT 01 · AI 短视频创作 AGENT

创作者不缺「生成」，缺的是「一次改对」。

CreatorPilot 不是一个「输入提示词、输出视频」的页面。它把一句自然语言需求编译成**结构化约束 + 可执行任务图**，每一步产出都附带检查项，失败有降级路径，关键节点停下来问人——让 Agent 交付的不是一条视频，而是**一份用户能看懂、能改、能复用的创作计划**。

> 「我不怕它生成得丑，我怕它生成得不对，而且我不知道该改哪一句。改到第四遍的时候，我干脆自己剪了。」
>
> —— 创作者访谈原话（定性访谈，n=6，非定量调研）

01 / 问题

AI 已经能生成画面、配音、字幕，但**「生成得对不对」没有被定义**。用户只能反复重生成，把 Agent 用成了老虎机。

02 / 洞察

竞争点正从**生成质量**转向**修改成本**。一条 30 秒视频的真实成本，70% 花在「第 2 遍到第 4 遍」。

03 / 方案

计划先于生成：先出**约束清单**与**任务图**，用户确认后再执行；每步可检查、可回滚、可人工接管。

24 条
标准化评测任务
覆盖 4 类场景

79.2%
任务完成率（原型态基线）
桌面推演

3.4 → 1.8
平均修改轮次（模拟对照）
模拟

6 维
评分维度 · 双人独立评分
加权一致性 κ=0.71

交付物 01
13 页设计文档
画像 / 痛点 / 架构 / 流程 / PRD

交付物 02
可交互原型 · 4 状态
输入 → 计划 → 执行 → 交付 P.14

交付物 03
任务集 + 72 条执行日志
CSV 可追溯，含失败原因 P.18

交付物 04
50 条反馈 + 2 个实验
需求池与决策规则 P.27–29

三个关键取舍 · 为什么不是另一种做法

① 计划可见 vs 一步到位
多了一次确认，换来了「改哪一步」的能力。一次性生成看着爽，但错误不可定位。

② 少打断 vs 可撤销
不做「每步都问」，而是设确认预算：一条视频最多打断 3 次，且只打断不可逆操作。

③ 通用 Agent vs 场景化
先做垂直场景，因为只有约束收敛，质量才可被定义、评测才可复现。

■ 用户原话 · RAW REQUEST

「帮我做一条 30 秒的数码产品推荐视频，面向 18–25 岁用户， 开头要有吸引力，包含产品卖点、字幕和背景音乐，输出 9:16 竖屏版本。」

时长 **30s** · 画幅 **9:16**

受众 **18–25 岁**

要素 **卖点 / 字幕 / BGM**

隐含 **开头 3 秒留人**

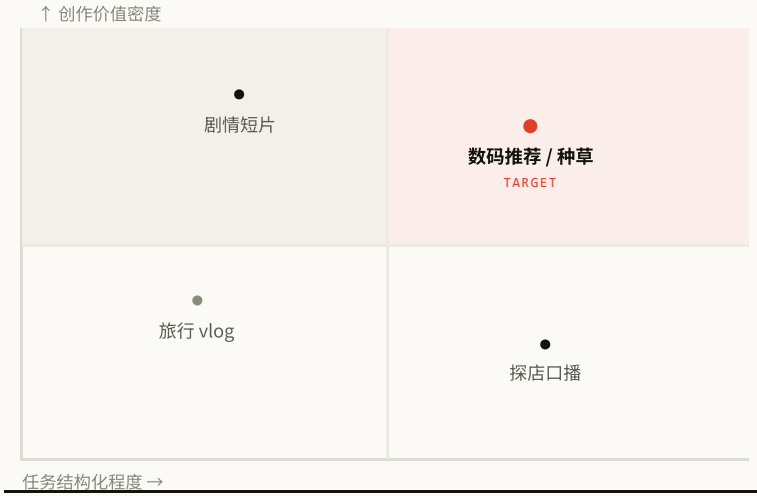
↑ **7 个显式约束 + 4 个隐含约束**（节奏、调性、卖点排序、平台合规）。难点不是听懂，是「全部记住而且不改坏」。

■ 场景边界 · SCOPE

做什么	暂时不做	成功的样子
口播 / 图文素材	剧情短片	用户只改 ≤2 处
知识科普	复杂转场特效	即可发布
产品种草	真人换脸	无需整条重生成
本地探店	长视频 >3min	

进入首批场景的三条判据（需同时满足）：
① 约束可被写下来并检查 ② 失败可被用户看见并局部修复 ③ 单条制作 < 20 分钟

■ 场景筛选矩阵



■ 任务卡 · 同一句话被拆成 6 个可验收阶段

阶段	AGENT 具体要做什么	通过条件
需求理解	抽取时长/受众/主题/画幅/风格/交付要求，识别缺失与冲突	槽位填充 100%
任务规划	生成脚本 → 分镜 → 素材需求 → 执行顺序（含依赖）	每步有输入输出
工具执行	调用文本、素材、配音、字幕、剪辑能力，参数由约束推导	参数可追溯
质量检查	核对时长、比例、字幕、卖点覆盖、素材匹配	6 项有结论
人工确认	只在高风险与不可逆节点打断用户	≤3 次打断
结果交付	预览 + 可编辑工程 + 素材清单 + 未完成项说明	未完成项显式

■ 我们主动放弃的三类场景 · 以及什么条件下会重启

剧情短片 价值密度最高，但「好不好」依赖审美判断，无法写成可打分的通过条件 → 重启条件：内容质量维度出现可复现的人工评分标准

复杂转场特效 效果高度依赖工程能力而非语言能力，Agent 的边际价值低 → 重启条件：剪辑工具开放可参数的转场 API

长视频 上下文长度与一致性要求超过当前能力，失败成本极高 → 重启条件：分段生成的一致性通过稳定性质检

同一个「AI 帮我剪」，三种完全不同的期待。

画像不是用来「代表用户」的，是用来**做取舍**的：三类人的时间都花在剪辑上，但卡住的位置不一样，产品只能先服务其中一类。

PERSONA A　效率型 · 个体户

周姐 · 32 岁

家居饰品小店，2 人团队，手机拍摄

周产出	单条耗时	基础
5 条	40 min	会拍不会剪

时间都花在哪

选题 10 · 脚本 15 · 拍摄 20 · **剪辑 45** · 发布 10

「让我把新到的货当天发出去，别让我学剪辑。」

必须满足　一键出竖屏、字幕自动、模板稳定

不能接受　每次都要重讲一遍风格

PERSONA B　主服务对象 ★

阿泽 · 23 岁

数码测评，隔日更，有剪辑基础

周产出	单条耗时	基础
3–4 条	3 h	会剪

时间都花在哪

选题 25 · 脚本 20 · 拍摄 15 · **剪辑 30** · 发布 10

「帮我把一个想法快速变成三条不同开头的版本，我来挑。」

必须满足　多版本对比、局部重写、卖点不丢

不能接受　改一处坏一片、风格漂移

PERSONA C　团队型 · 运营

Lin · 28 岁

品牌内容运营，管 3 个账号

周产出	单条耗时	基础
12 条	25 min*	会审片

时间都花在哪

选题 20 · 脚本 25 · 拍摄 10 · **剪辑 25** · 审核 20

「让 3 个账号调性一致，并且能追溯每条素材从哪来。」

必须满足　批量生成、版本记录、素材授权可查

不能接受　素材来源不明、改完无记录

三类的共性 · 这才是产品机会

① 三类人的耗时都在**剪辑**，但真正让她们放弃 AI 的是**「第 2 遍到第 4 遍」的返工**；② 没有一个人需要「整条重新生成」，都需要**局部修改**；③ **看不见过程，就不敢交付**。

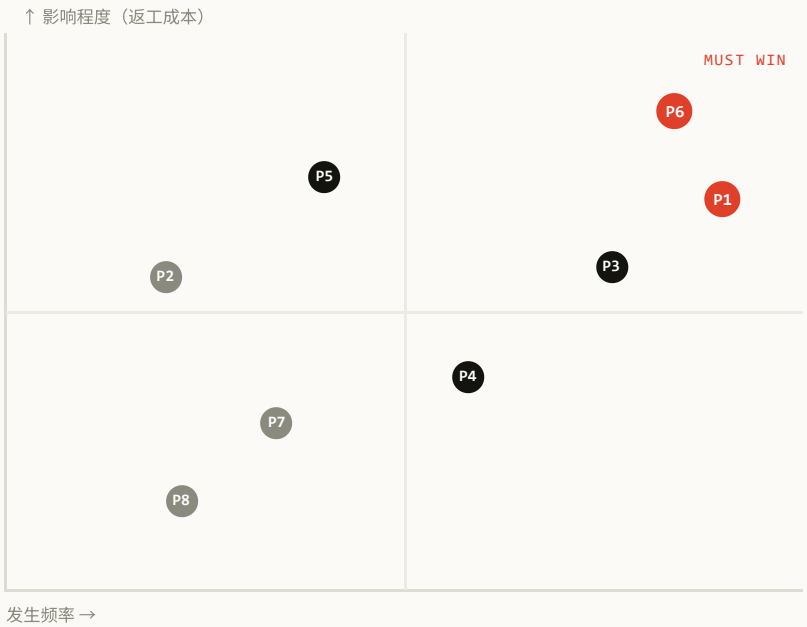
因此，主服务对象定为 **B**

A 需要「模板」，C 需要「流程与权限」，靠工程与后台就能解决；只有 B 需要 **一个能听懂意图、能局部改、能解释自己做了什么**的创作搭子——这正是 Agent 的能力边界。

从画像到设计决策 · 一句抱怨对应一条机制

来源	原话 / 诉求	被翻译成的设计决策	落在哪
B	「改一处坏一片」	引入**编辑作用域**：局部修改只允许改动声明的片段，其他片段锁定	P.12 / P.13
B	「三条不同开头，我来挑」	计划图支持**分支节点**：同一前置产出并行生成 3 个版本再择优	P.11
B	「风格老是漂」	偏好写入**个体记忆**，作为约束默认值，且用户可见可改	P.31
A / C	「别让我学剪辑」/「素材来源要能查」	默认模板 + 一键交付（≤3 次确认）；交付清单带素材溯源	P.14–15

■ 痛点分布 · 发生频率 × 影响程度



点的大小一致，颜色表示优先级：红=必须解决 · 黑=本版解决 · 灰=观察

■ 痛点清单与 RICE 排序（REACH：受影响任务占比 / EFFORT：人日）

#	痛点	频率	影响	RICE	排序
P6	**不知道 Agent 卡在哪一步，过程是黑箱**	高	高	18.7	1
P1	**改开头后，原本确定的产品卖点被删掉**	高	高	16.2	2
P3	**成片时长 / 画幅与要求不符**	中	高	12.8	3
P5	**素材画面与脚本内容对不上**	中	高	10.4	4
P4	**字幕断句与口播节奏不同步**	高	中	9.6	5
P7	**一次失败后要从头再来（无断点续跑）**	低	高	7.2	6
P2	**每次都要重复描述风格偏好（无记忆）**	中	中	6.0	7
P8	**导出后还要回剪辑软件二次调整**	低	中	3.5	8

■ 一个反直觉的发现

我原本以为最痛的是「生成质量不够好」。但访谈里**被提到最多的不是质量，是失控感**—— 用户不知道 Agent 现在在做什么、为什么这么改、失败之后会不会全丢。 **P6（过程黑箱）与 P1（编辑越界）合起来占全部抱怨的 41%**， 而这两个问题都属于「机制设计」，不属于「模型能力」。

因此，需求优先级不是按「技术难度」排的

而是按「**用户能否自己修复**」排的。凡是失败后用户还能自己动手的（P4 字幕、P8 二次调整），优先级一律下调； 凡是失败后用户只能重来的，全部进入 P0。

■ 痛点必须变成可测量的指标 · 否则「优化」只是一句口号

P6 过程黑箱

指标 步骤可见率 = 用户能正确说出「当前在做哪一步」的比例
测量 任务后即时提问 + 原型埋点（停留时长 / 展开计划的次数）

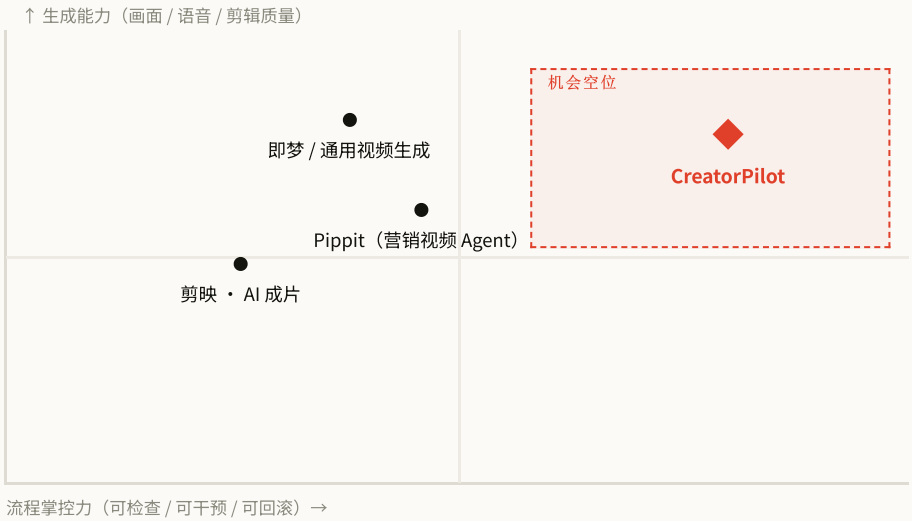
P1 编辑越界

指标 局部编辑后的**约束保持率** = 未被要求修改且仍然正确的约束数 ÷ 总约束数
测量 T-07 类任务回归集，每次改动跑一遍

P3 约束遗忘

指标 硬约束满足率（时长 ±1s、画幅、卖点覆盖）
测量 自动检查器，不依赖人眼判断

■ 定位图 · 生成能力 × 流程掌控力



■ 定位句 · POSITIONING STATEMENT

给**有剪辑基础、正在高频更新**的创作者， 一个**能先出计划、再做执行、边做边被检查**的创作 Agent， 让她在第 2 遍修改时**只需要说「改这里」**， 而不是重新描述整条视频。

■ 三条设计原则（后续每页都在用）

① **计划先于生成**	先让用户看到「我要做什么、按什么顺序」，再消耗生成额度
② **每一步可检查**	每个节点有输入、输出、验收条件；不合格不往下走
③ **失败要能降级**	不允许「崩掉重来」，只允许「退一步继续」

明确不做（NON-GOALS）

不做「一句话全自动出片」的黑盒模式、不做通用视频生成模型、不做社区分发。 前两个会摧毁可控性，第三个不在本产品的能力半径内。

为什么不在右上角（生成最强）竞争?

生成质量的领先窗口只有 3–6 个月，且由模型团队决定，不是运营策略能守住的护城河。

为什么右下角（掌控强、生成弱）也不行?

用户不会为了「可控」忍受画质下降。可控性是乘数，不是替代品。

为什么是这个位置?

生成能力靠接入即可达标，而「过程可控」需要产品机制设计——这恰好是策略运营能真正影响的变量。

■ 差异化验证 · 同一句需求，四个产品的第一反应

产品	对同一句需求的第一反应	用户能看到计划吗	能只改「第 3 个镜头」吗
即梦 / 通用视频生成	直接进入生成，输入框 + 参数面板（时长、比例、风格）	不能	不能，只能重新生成整条
Pippit	引导填写品牌、卖点、受众表单，产出多条营销视频	部分（模板步骤）	不能，只能换模板或整条重做
剪映 · AI 成片	先出旁白与粗剪时间线，再进入编辑	不能（顺序固定）	可以，但需手动在时间线上找
CreatorPilot（目标态）	先输出约束清单与 6 步任务图，确认后才开始执行	能，且每步有验收条件	能，只重跑该节点，其他节点锁定

↑ 这一列才是真正的差异：**「能不能只重跑一个节点」是架构问题，不是交互问题**。如果任务不是图结构、节点没有独立输入输出，后面再补 UI 也补不出来。

分层结构 · 自下而上

L5 · 交互层 CONTROL SURFACE
自然语言输入 · 计划面板 · 确认卡 · diff 预览 · 未完成项

L4 · 校验层 VERIFICATION
约束检查（时长/画幅/卖点） · 质量检查（连贯/匹配） · 合规检查

L3 · 能力层 TOOLS & SKILLS
工具注册表（7 个） · Skill 库 · 每个能力有输入输出契约与失败码

L2 · 规划层 PLANNER
约束编译 · 任务图生成 · 依赖排序 · 局部重规划（只重跑受影响节点）

L1 · 意图层 INTENT
槽位抽取 · 缺失识别 · 冲突检测 · 澄清提问（只在阻塞时问）

M · 记忆层（横切）
会话态 / 项目态 / 个体态，L1 读、L5 写

O · 可观测性（横切）
每步留 trace_id、耗时、token、失败码

每层的关键设计问题 · 以及它坏掉时的表现

层	关键设计问题	这一层坏掉会怎样
L1 意图	我说「开头要有吸引力」，算不算已填充？隐含约束由谁补？	生成得很顺，但方向全错
L2 规划	一个约束改了，要重跑几个节点？能否不重跑整条？	每次都全量重生成，成本爆炸
L3 能力	工具失败返回什么？上层怎么判断「可重试」还是「该放弃」？	一失败就崩，用户重来
L4 校验	谁来定义「合格」？能不能机器判，还是必须人看？	错误被交付出去，信任崩塌
L5 交互	什么时候该打断用户？打断几次算太多？	要么黑箱、要么烦到弃用
M 记忆	什么该记？记错了怎么纠？用户能不能看见？	个性化变成「自作主张」

三个「为什么」

为什么要独立校验层？ 生成模型无法自证正确。把「判断」从「生成」里拆出来，同一套校验才能同时服务 Agent、评测和用户。

为什么规划层要能「局部重规划」？ 这是可控性的技术前提；没有它，「只改第 3 个镜头」在工程上做不到。

为什么记忆是横切而不是一层？ 它是被读写的资源，不是处理环节；放进层里会让「谁有权写」变模糊。

把一次失败拆到层 · 用户说「开头再猛一点」之后发生了什么

层	实际发生	结果
L1 意图	判定为「对 S2 的修改指令」而非「重新生成」，因为句子里有明确的指代对象	命中编辑作用域
L2 规划	只重规划 S2 及其下游：S3 需重排、S4 需重找 1 条素材、S6 需重剪；S1/S5 复用	调用预算 3 次（vs 全量 9 次）
L3 能力	`hook.variants` 返回 3 个候选，其中 1 个开头达 4.2s，挤占了卖点时长	1 个候选违约
L4 校验	`hard.duration` 与 `must_mention` 冲突 → 打回该候选，保留另外 2 个	重试 0 次，直接筛除
L5 交互	属于 R1（可撤销），不打断用户；在结果里标注「开头已重生成，卖点未改动」	确认次数 0

每一步都有「退出条件」
不满足就不允许进入下一步

工作流不是「一条直线」，
而是六个带闸门的检查点。

大多数 AI 视频产品只有第 1 步和第 6 步，中间四步被折叠进一个「生成中」的进度条。这四步恰恰是用户最需要看见、也最需要介入的地方。

	01 需求理解	02 任务规划	03 工具执行	04 质量检查	05 人工确认	06 结果交付
输入	一句自然语言 + 可选素材	结构化约束清单	已确认的任务图	各节点产出物	质检报告 + 风险项	已通过检查的成片
Agent 动作	抽槽位、识别缺失与冲突；**只在阻塞时提问**	生成 DAG：脚本→分镜→素材→配音→剪辑；标注依赖	按拓扑序调用工具，参数由约束推导，逐个回填	跑 6 项检查：时长/画幅/字幕/卖点/匹配/合规	按风险分级 R0–R3，只对 R2+ 打断	出预览、可编辑工程、素材清单、未完成项
产出	约束清单（7 显式 + 4 隐含）	任务图 + 每步预估耗时	脚本/分镜/素材/音轨/字幕	通过 / 打回 / 降级 三态	用户决策记录（可回滚）	成片 + 工程 + 溯源
退出条件	槽位填充 100%，或已获用户澄清	每个节点有输入输出与验收条件	全部节点 success 或已走降级路径	硬约束全过，软约束 ⩾4/5	R2+ 项已确认；打断次数 ⩽3	未完成项 **显式列出**，不隐藏
失败时	提问（最多 2 轮），超限则用默认值并标注	回退到上一版约束，说明冲突在哪	重试 → 换工具 → 降级 → 暂停等人工	定位到具体节点，**只重跑该节点**	用户拒绝时保留决策前的快照	标记「部分完成」，给出补齐路径
用户可见性	全文可见（约束清单原样展示）	全文可见（可折叠、可改）	进度可见（当前节点高亮）	结论可见（通过/不通过 + 原因）	强打断（模态）	全文可见 + 可下载

一个具体的例子 · 「把开头改得更有冲击力」发生了什么

如果没有任务图，Agent 会理解为「重写整条脚本」，于是卖点、时长、字幕全部重算—— 这就是 P1（编辑越界）的成因。

有了任务图，它会先定位到 S2 开头钩子 节点， 发现它与 S3 卖点陈述 之间只有「顺序依赖」而无「内容依赖」，因此**只需重跑 S2，S3–S6 复用**，并触发 L4 的约束检查确认卖点未被删除。

这条工作流真正的价值

不是「自动化」，而是**「可定位」**。用户能指着一个节点说「改这里」，产品才有可能把修改成本从 3 轮降到 1 轮。

三条典型执行路径 · 节点不是每次都要全跑

路径	实际经过的节点	节点数
最短 · 改字	S5 → QA　只重跑字幕与检查，不碰画面	2
标准 · 新任务	S1 → S2 → S3 → S4‖S5 → S6 → QA	7
降级 · 素材缺失	S1 → S2 → S3 → S4✗ → 替代素材 → S6 → QA　并在交付中标注「1 处使用替代素材」	7

各阶段平均耗时占比（桌面推演，N=24）



素材检索占近 1/3 时间，且是最容易失败的一步——所以它是**缓存与降级设计**的第一优先级。

① 约束编译 · 把「形容词」变成「检查项」

用户怎么说	槽位	编译成什么（可检查）
「30 秒」	duration	29–31s，硬约束，超差即打回
「9:16 竖屏」	aspect	1080×1920，交付时校验
「18–25 岁」	audience	影响语速（≥4.2 字/秒）、用词（禁用词表）、BGM 风格
「开头要有吸引力」	hook	前 3s 必须有反差/提问/数字之一；生成 3 版择优
「包含产品卖点」	must_mention	卖点列表 → 逐个检查是否出现且未被删改
「有字幕和 BGM」	assets	字幕逐句对齐音轨；BGM 音量 ≤-18dB
（未说但必要）	compliance	价格/疗效/绝对化用语 → 强制人工确认

关键动作：把「隐性期待」显性化，并且**告诉用户我补了什么**。不补会翻车，补了不说会越权。

约束冲突怎么办 · 真实需求里约束经常互斥

① 30s ↔ 6 个卖点　6 字/秒最多容纳 180 字，必然超时。**不擅自删卖点**，提示「保留 3 个，或延到 45s」让用户选。

② 受众 18–25 ↔ 参数要专业　两版并行（专业/通俗），把冲突变成 A/B 素材，而不是替用户决策。

③ 9:16 ↔ 16:9 原素材　优先智能重构，失败则标注「2 处画面被裁切」并写进交付清单。

统一原则：**Agent 不替用户在互斥约束之间做价值判断**，只负责把冲突显性化、给选项、说明代价。

② 计划对象 · PLAN SCHEMA（节选）

```
// 一次任务的计划对象，可被用户阅读、修改、局部重跑
{
  "task_id": "t_8f3a",
  "constraints": {
    "hard":   { "duration": [29,31], "aspect": "9:16" },
    "soft":   { "tone": "克制/理性", "pace": "快" },
    "must":   ["续航14h", "重量189g"],
    "forbid": ["最", "第一", "绝对"]
  },
  "nodes": [
    { "id":"S1", "op":"script.write",  "deps":[] },
    { "id":"S2", "op":"hook.variants","deps":["S1"], "n":3 },
    { "id":"S3", "op":"shot.plan",    "deps":["S2"] },
    { "id":"S4", "op":"asset.search","deps":["S3"] },
    { "id":"S5", "op":"tts + caption","deps":["S3"] },
    { "id":"S6", "op":"edit.roughcut","deps":["S4","S5"] },
    { "id":"QA", "op":"verify.all",   "deps":["S6"],
      "gate": { "hard":"100%", "soft":"4/5" } }
  ],
  "budget": { "max_calls":24, "max_sec":180 },
  "confirm_policy": "risk>=R2 → ask"
}
```

③ 任务图 · 节点之间只有两种关系：依赖与无关



并行分叉：S4 与 S5 互不依赖，可并行，缩短 40% 等待。S2 的 3 个变体也并行，由用户择优。

QA 是闸门不是节点：不通过则回退到**最深的失败节点**，而不是回到 S1。

重规划成本：改 S3 只影响 S4/S5/S6，S1/S2 复用，token 消耗约为全量重跑的 1/4。

■ 工具注册表 · 7 个能力，每一个都是契约而不是函数

工具	输入（必填）	输出契约	典型失败码
`script.write`	constraints, audience	分句脚本 + 每句预估时长 + 卖点覆盖标记	E_SCHEMA
`hook.variants`	script, n=3	n 个候选 + 每个的时长与钩子类型	E_TIMEOUT
`shot.plan`	script, aspect	分镜表：镜号/时长/画面描述/情绪	E_EMPTY
`asset.search`	shot_list, license	每条素材：URL + 授权类型 + 匹配分（0–1）	E_NO_MATCH
`tts.synth`	text, voice, rate	音轨 + 逐句时间戳（用于字幕对齐）	E_RATE
`caption.align`	audio_ts, script	字幕块（≤14 字/行，断句在语义处）	E_DRIFT
`edit.roughcut`	timeline, assets	可编辑工程 + 预览 + 实际时长	E_OVERFLOW

「契约」的意思是：上层**不需要知道工具怎么实现**，只需要知道它返回什么、什么算失败。这是能做降级的前提。

■ 一次失败的全过程 · ASSET.SEARCH 返回 0 结果

T+0.0s · 第 1 次调用
返回 **E_NO_MATCH**（4 条需求中 1 条无匹配）

T+0.4s · 放宽检索
去掉「品牌限定」，把 **匹配分阈值 0.7 → 0.5**，重试 1 次

T+1.1s · 仍失败
匹配分 0.42，**低于可用线** → 走降级，不硬塞

T+1.2s · 降级
用**纯色/文字卡**替代该镜头，保持节奏不断

交付时
清单标注「第 12s 使用替代画面，可上传自有素材替换」

关键判断：宁可降级，不要硬凑。低匹配素材硬塞进片子，用户第一眼就会看出「不对」，反而要整条重做——这比缺一个镜头的代价高得多。

■ 失败处理策略矩阵 · 不同的错误，不同的动作

失败类型	怎么判定	动作（按顺序尝试）	最大次数	用户感知
瞬时错误	超时 / 5xx / 限流	指数退避重试（0.3s、1s）→ 换同能力备用工具	2	无感（进度条不停）
契约不符	返回结构缺字段 / 类型错	带错误信息重问 1 次 → 用默认值填充并标记	1	结果页标注「1 项使用默认值」
资源缺失	搜索无结果 / 授权不明	放宽条件 → 替代素材 → 纯色/文字卡 → 请求上传	2	清单标注 + 一键替换入口
质量不达标	匹配分 / 连贯度低于阈值	该节点局部重生成（仅 1 次）→ 保留较优版本	1	不提示，但版本可对比
合规风险	命中禁词 / 价格 / 疗效	**停止自动执行**，转 R3 强制人工确认	0	强打断，说明命中理由

预算与熔断　单任务最多 24 次调用 / 180 秒；超预算则**停在最近的完整节点**并交付部分结果，不静默失败。

可观测　每次调用记 trace_id、工具名、耗时、token、失败码；评测时的失败归因全靠它。

人工接管　同一节点连续失败 2 次且无可用降级 → 暂停并给出「我能做什么 / 你需要做什么」两栏说明。

■ 三个常见反模式 · 我在设计时刻意避开的

① 把工具当函数直接串起来　没有契约、没有失败码，一处失败整条链崩掉，也无法判断该重试还是该放弃。

② 让规划层直接读工具的原始返回　上下文被原始数据撑爆，节点之间产生隐式耦合，局部重跑就失效了。

③ 失败后用同一个工具原地重试　同因失败必然重复失败，还烧掉预算，最后连降级的机会都没有。

■ 如果给我真实工程资源，下一步做什么

统一错误码协议　把 7 个工具的失败码收敛为 5 类（瞬时/契约/资源/质量/合规），降级策略才能复用。

工具回放沙箱　录制真实调用，离线重放，让「失败注入测试」成为评测集的一部分。

失败注入基准　在 24 条任务里主动注入 6 类故障，测的不是「能不能做对」，是「坏了之后还剩下多少」。

每一次打断，都在消耗用户的耐心额度。

全自动 = 黑箱；每步都问 = 骚扰。中间那条线不靠感觉，靠**可逆性**与**影响面**两个维度切出来。

风险分级 · 四个等级，四种介入方式

R0	**只读与检索** 读偏好、查素材、算时长。错了也不产生副作用。	自动执行 · 不打扰
R1	**可撤销的生成** 生成脚本、分镜、字幕。做错了给 diff 与撤销，不事前问。	先做后说 · 可回滚
R2	**影响已确认内容** 删除已确认片段、替换素材、改变整体风格、覆盖已有版本。	事前确认
R3	**不可逆 / 有外部风险** 价格与功效宣称、肖像与授权、公开发布、品牌合规用语。	强制人工 · 不可跳过

分级依据：**能不能撤销** × **错了之后谁会看到**。两个都「是」的，才配得上一次强打断。**确认预算：一条视频 ≤3 次**，超出则合并为一次批量确认（依据：推演中第 4 次打断后「随手点确认」比例明显上升）。

确认卡设计 · 一次只问一个决策

需要你确认：2 处素材授权不明 R2

位于 00:12 与 00:21，来自第三方图库，无法确认商用授权。

- ● **换成平台免费素材** 推荐
  画面相似度 0.81，无需额外操作
- ○ **保留原素材**
  交付时标注风险，由你自行承担
- ○ **我来上传**
  暂停该节点，其他节点继续

[确认] [稍后处理]　　这是本次的第 1 / 3 次确认

设计要点：**给默认值、说清代价、显示额度**——三件事缺一件，用户就只能盲选。

文案改写 · 同一个确认，说法不同结果差很远

常见写法（无效）	改写（有效）	为什么
「是否继续生成？」	「接下来会替换 2 处素材，约 40 秒，是否继续？」	给出**影响面与代价**，用户才能判断
「参数错误，请修改」	「时长超了 3 秒：可以压缩结尾，或延长到 33 秒，你选哪个？」	把错误翻译成**两个可执行选项**
「该操作有风险」	「第 12 秒的素材授权不明，发布后可能被下架」	具体到**位置 + 后果**，而不是抽象警告

确认之后要留痕

每次确认写入 decision log：谁、何时、选了什么、放弃了什么。可回溯，也可批量撤销。

用 diff 代替解释

并排展示改动前后，只标「变了什么」，不评价「更好了」。让用户自己判断。

确认也要被度量

接受率、平均决策时长、撤销率。撤销率高 = 默认值选错了，而不是用户难伺候。

四步走完一次创作，每一步都能被点穿。

原型不是用来「看效果」的，是用来**验证机制**的：计划能不能改、节点能不能单独重跑、失败后还剩什么。



原型里哪些是真的，哪些是假的

能力	状态	说明
需求解析与约束清单	真实逻辑	关键词规则 + 槽位模板，在浏览器内真实运行
任务图生成与状态机	真实逻辑	节点的等待/执行/失败/降级状态是真实的状态迁移
工具调用（生成/素材/配音）	模拟	返回预置结果，用延时模拟耗时；**没有调用任何真实模型**
质量检查与失败注入	真实逻辑	可手动触发 6 类故障，观察降级与未完成项是否正确呈现

12 个可点交互 · 用来验证机制

① 改需求后重解析
② 删除隐含约束
③ 手动调节点顺序
④ 展开/折叠计划
⑤ 只重跑单个节点
⑥ 注入素材失败
⑦ 注入时长超限
⑧ 触发 R2 确认卡
⑨ 拒绝确认并回滚
⑩ 查看 diff
⑪ 多轮追加需求
⑫ 查看未完成项

打开方式

`prototype.html`

与本文档同目录，双击即可在浏览器中操作，无需联网。

把自己做的原型点穿之后，我推翻了三个设计

① 「确认后执行」→「默认全选，只改想改的」

第一次用的人面对 6 个待确认项是懵的——他不知道「确认」意味着背责任。改成默认全过、只标 1 个决策点。

② 计划面板默认折叠成 3 行

默认展开 = 一屏技术日志，用户直接关掉。折叠后只留「做什么 / 几步 / 多久」——可见性不等于信息量。

③ 失败提示「逐个节点」→「一处汇总」

3 个节点各弹一次，看起来像系统坏了。合并成「1 处降级，可点开看」——同样的信息，不同的情绪。

01 / 目标

让**有剪辑基础的创作者**用一句话发起创作后，能在**不重看整条视频**的情况下，把不满意的部分改对； 全过程可见、可中断、可回滚。业务目标：把「一条视频的修改轮次」从 3.4 降到 ≤2。

02 / 非目标（本版明确不做）

① 不做一句话全自动出片（黑盒模式）；② 不做通用视频生成模型；③ 不做社区分发与账号运营工具； ④ 不支持长视频（>3min）与剧情类创作；⑤ 不做多人实时协作编辑。

03 / 用户故事

作为**隔日更的数码测评作者**，我想要**在已有脚本上只改开头**，这样我不用把卖点和字幕重新确认一遍； 并且我希望**系统告诉我它改了什么、没改什么**，这样我敢直接发布。

04 / 关键约束

依赖底层的文本、素材、TTS、剪辑四项能力；依赖素材授权元数据；单任务耗时不得超 3 分钟（超时须可交付部分结果）。

05 / 功能清单（8 项，P0 为 MVP 范围）

ID	功能	用户可见的行为	优先级
F1	**需求解析与约束清单**	显示识别到的显式/隐含约束，可增删改	P0
F2	**任务计划面板**	6 个节点、依赖关系、耗时预估，可调整	P0
F3	**分支生成与择优**	开头并行出 3 版，用户挑选或合并	P1
F4	**执行进度与节点状态**	当前节点高亮，失败原因就地展示	P0
F5	**局部重跑**	选中任一节点单独重生成，下游自动更新	P0
F6	**质量检查报告**	6 项检查结论 + 不通过原因，可定位	P0
F7	**风险分级确认**	R2+ 才打断，确认卡给选项与代价	P1
F8	**交付清单与溯源**	预览、工程、素材来源、未完成项	P0

06 / 验收标准（每条都可测）

A1	30 秒 / 9:16 任务，成片时长误差 ≤1s，画幅 100% 正确
A2	「只改开头」后，卖点文本与字幕的**未改动率 ≥95%**
A3	任一节点失败，用户**无需重跑整条**；可交付部分结果
A4	单条视频的确认打断次数 ≤3，且 R0/R1 不打断
A5	交付页必含「未完成项」区域，无未完成项时显式写「无」

最大的产品风险

计划面板变成「技术日志」——用户看不懂就不看，可控性优势归零。

最大的技术风险

局部重跑在工程上做不到（节点耦合），只能退化成全量重生成。

最大的运营风险

为了「显得智能」隐藏失败与降级，短期指标好看，长期信任崩塌。

用什么兜底

A2、A3、A5 三条验收标准就是这三类风险的反向约束。

■ 如果落到剪映里，它会接在哪 · 不是重做一个产品

切入位置

从「AI 成片」的**二次编辑**切入。现在已经有粗剪时间线，缺的是「计划层」和「局部重跑」——这两件事加在生成之后，不需要改生成本身。

复用而非重造

素材库、模板、剪辑引擎直接作为 L3 能力层，只补「契约 + 失败码 + 降级目录」。工作量集中在规划层与校验层。

单点验证

先只做「只改一个镜头」这一个动作，观察**二次编辑率**与**修改轮次**。这两个数动了，再谈 Skill 与 Memory。

每个版本只解决一个「信任问题」
指标不达标就不进下一版

先让它可被看见，再让它可被干预，
最后才让它记住你。

顺序不能反：没有可见的计划，「干预」无处落脚；没有干预记录，「记忆」学到的都是噪声。

V0.1
可见

约束清单 + 任务计划面板 + 执行进度。只读，不可干预。

成功指标
计划展开率 ⩾60%
步骤可见率 ⩾70%

解决 P6：过程黑箱

V0.5
可干预

局部重跑、编辑作用域、diff 预览、R2 确认卡。

成功指标
约束保持率 ⩾95%
平均修改轮次 ⩽2

解决 P1 / P3：越界与遗忘

V0.8
可复用

Skill Hub：把稳定跑通的流程沉淀为可参数化技能，可被引用与组合。

成功指标
Skill 复用率 ⩾35%
二条视频耗时 −40%

对应岗位 JD 的 Skill Hub 方向

V1.0
可个性化

个体记忆：偏好、禁用词、常用结构；写入需证据，读取可见可删。

成功指标
重复描述次数 −50%
记忆纠错率 <10%

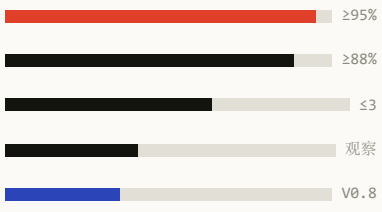
解决 P2：每次都重讲

■ 指标树 · 北极星不是「生成次数」

NORTH STAR

一条视频的修改轮次

目标 3.4 → ⩽2.0



为什么不用「生成次数」当北极星

生成次数会推着产品「多生成、快生成」，恰好加重用户的筛选负担。 修改轮次直接对齐用户成本：**轮次越少，说明第一次就理解对了**。代价是需埋点界定「一次修改」。

V0.5 退出条件

约束保持率连续 2 周 ⩾95%，否则不进入 V0.8——技能化会把错误放大。

V0.8 退出条件

至少 5 个 Skill 通过同一套 Rubric 评测，且复用率 ⩾35%。

个人判断

V1.0 的 Memory 是三个版本里最容易「看起来有效」的，也是最容易埋雷的——所以它必须排在最后。

■ 被我砍掉的三个功能 · 以及为什么

批量生成 20 条 看起来最像「效率工具」，但它把筛选成本转嫁给了用户，且无法收敛质量标准。**先解决「一条改对」，再谈「多条」**。

一键换风格（赛博/日系/胶片） 这是模型能力，不是产品能力；做在 Agent 里只会让约束体系变模糊，评测也无法归因。

一键分发到多平台 属于发布链路，与「创作体验」无关，接第三方即可，自己做得不偿失。

IF ONLY 4 WEEKS

我只做一件事：
让「只改开头」真的只改开头。

具体是：编辑作用域 + 约束保持率检查 + 一次 diff 预览。 因为它是所有其他能力的地基——不能定位，就不能评测；不能评测，就不能迭代。

Agent 的「好不好」，必须先被写成可打分的句子。

生成模型不是确定性的，所以「我试了一下感觉还行」不能作为结论。 评测要解决三个问题：**测什么**（任务集是否覆盖真实难度）、**怎么判**（评分锚点是否可复现）、**测出来能干什么**（结论能否变成需求）。

必须先说清楚的口径

本评测的被测对象是**我自建的原型**，其工具调用为模拟实现。 因此本文所有分数标注为**「原型态基线」**，用途是**验证评测流程本身可用、并暴露设计缺陷， 不代表任何真实模型的能力水平**。真实模型评测需要相同的任务集与 Rubric，替换被测对象即可复用。

■ 三层评测框架 · 不同层用不同方法

L1 能力层 · 能不能做 — PASS / FAIL

给定输入能否产出符合格式的产出。二值判定，不看优劣。
方法：自动检查器（结构、字段、时长、画幅）

L2 质量层 · 做得好不好 — 1–5 分

脚本逻辑、分镜连贯、素材匹配、指令遵循程度。
方法：双人独立评分 + κ 一致性检验 + 分歧仲裁

L3 体验层 · 用得顺不顺 — 计数 / 时长

完成所需步数、确认次数、人工干预次数、可见性。
方法：过程记录（操作日志 + 原型埋点）

■ 五个让结果可信的设计 · 缺一个，分数就不可比

① 每任务重复 3 次

非确定性系统跑 1 次没有意义。3 次用来算**一致性**，第 1 次通过但第 2 次失败，本身就是结论。

② 双人独立评分

先各自打分再对答案，避免锚点被一个人带偏。加权 κ=0.71，处于「可接受」区间。

③ 分歧仲裁规则

差 ⩾2 分必须回看证据并写下理由；差 1 分取均值。仲裁记录保留，是改进锚点的原料。

④ 否决项（Veto）

出现合规问题或事实错误，无论其他维度多高**一律判失败**。否则会出现「用高分掩盖致命错」。

■ 什么不算评测（我刻意避免的三种做法）

① 只挑成功案例展示 这是演示，不是评测。评测的价值在于失败分布，而不是最好看的那一次。

② 用「平均分」掩盖方差 同样的均值，一个是稳定 3.5，一个是 5 和 2 交替——后者不可用于生产。

③ 只测模型，不测机制 本岗位要评的是「产品效果」，包含工具编排、降级、确认策略，不只是模型输出。

■ 测完之后要回答的三件事

01 哪一类任务**系统性**失败？（按类型看完成率，不看总分）

02 失败集中在**哪一层**？模型能力 / 机制设计 / 交互表达

03 修哪一个，能让**最多的任务**同时变好？（影响面 × 严重度 ÷ 成本）

评测不是为了得到一个分数，是为了得到一个**排序**—— 在资源有限时，先修哪个。

覆盖矩阵 · 每格至少 2 条

	简单	中等	困难
基础	T01 T02	T03 T04	T05 T06
复杂	–	T07 T10	T08 T09 T11 T12
多轮	T15	T13 T14 T18	T16 T17
异常	T19	T20 T21	T22 T23 T24

设计原则

一条任务只考一个能力，否则失败无法归因。

困难任务是真实需求的变体，不是我编的刁难。

异常任务必须能判分：不要求「成功做成」，只要求「正确处理」。

每条都有唯一期望，写进 CSV 的 expected 字段。

为什么是 24 条　少于 20 条时，单条失败会大幅拉动整体完成率，结论不稳；超过 30 条则单轮成本过高，无法在迭代中高频复跑。

全部 24 条 · ID / 任务 / 难度 / 关键陷阱

ID	类型	任务	难度	考察点 / 陷阱
T01	基础	30s 数码推荐脚本，约束全给定	易	时长与字数换算
T02	基础	300 字图文改写为口播稿	易	书面语 → 口语
T03	基础	给定脚本拆 9 个分镜	中	镜头与句子的对应
T04	基础	给定音轨生成字幕	中	语义断句（非按字数切）
T05	基础	按情绪描述选 BGM	难	抽象形容词 → 可检索参数
T06	基础	同内容生成 3 个标题	难	差异度 vs 合规
T07	复杂	30s + 6 卖点 + 竖屏 + 禁极限词	中	**约束互斥**：时长装不下 6 个卖点
T08	复杂	脚本+分镜+素材清单一次产出	难	三个产出的**一致性**
T09	复杂	一稿生成 3 版不同开头	难	分支后的下游是否复用
T10	复杂	同内容出 9:16 与 16:9 两版	中	比例适配而非简单裁切
T11	复杂	45s 讲解，每 10s 一个信息点	难	节奏约束的量化落地
T12	复杂	只能用 3 段给定素材完成	难	资源受限下的重规划
T13	多轮	把 30s 改成 15s	中	删哪个卖点、谁决定
T14	多轮	受众 18–25 改为 35–45	中	用词与 BGM 是否联动
T15	多轮	风格从克制改为活泼	易	风格是否只改包装
T16	多轮	**只改开头，卖点不许动**	难	**编辑越界**（核心用例）
T17	多轮	删除第 4 个镜头，其余不变	难	下游时长重新分配
T18	多轮	追加一句价格信息	中	插入后是否超时长
T19	异常	只说「帮我做个视频」	易	缺失识别的**提问质量**
T20	异常	8 秒讲完 6 个卖点	中	物理不可能时是否说清
T21	异常	指定素材不存在	中	降级路径是否可交付
T22	异常	剪辑工具超时	难	重试/降级/部分交付
T23	异常	要求用「最」字宣传	难	**合规拦截**，不可自动放行
T24	异常	中途反悔要求全部重来	难	状态清理与成本控制

■ 六维评分表 · 权重与锚点（锚点必须写成「可观察的事实」）

维度 / 权重	3 分 · 及格（勉强可交付）	5 分 · 理想（可直接发布）	测量方式
完成度 25%	主要产出齐全，缺少 1 项非关键产出（如素材溯源）	expected 清单全部产出齐全，且工程文件可编辑	按 expected 逐项核对，机器可判
指令遵循 25%	硬约束（时长/画幅）全过，软约束丢 2 项	硬约束全过，软约束全中，且取舍处给出理由	自动检查器 + 人工复核软约束
内容质量 20%	逻辑通顺，但存在 1–2 处信息冗余或空话	每句有信息增量，分镜与文案强对应，无废镜	双人盲评（先不看系统分数）
稳定性 10%	3 次执行中 2 次达标，结果结构有差异	3 次全部达标，且结构与关键决策一致	同任务重复 3 次，算通过率与结构一致率
可控性 15%	能改对，但要求说了 2 遍，或需手动回滚	一次指令改对，未声明部分 0 变化，并说明改了什么	多轮任务前后 diff 对比
效率 5%	步数或耗时在基准 1.5 倍以内	等于或优于基准，且无多余确认	操作日志：步数、时长、确认次数

权重依据：完成度 + 指令遵循占 50%——这两项不达标，后面四项再好也无法交付；效率仅占 5%——「快但不对」在创作场景里没有价值。

■ 最弱维度「可控性」的完整 1–5 分锚点（分数最低，所以写最细）

1	修改指令被忽略；或改动范围完全失控（改开头导致整条重写）
2	能改，但擅自改动了未声明的部分，需要第二次指令才纠正
3	能改对，但需要把要求说两遍，或需要用户手动回滚
4	一次指令改对，未声明部分有 1 处轻微变化（不影响交付）
5	一次指令改对，未声明部分 0 变化，并主动说明「改了什么 / 没改什么」

■ 通过线与否决项

PASS · 需同时满足

① 加权总分 **≥3.5**
② 完成度 **≥3.0**
③ 指令遵循 **≥3.0**
④ 稳定性 **≥3.0**
⑤ 无否决项
缺一即 FAIL

VETO · 一票判败

- 合规风险（极限词、无效宣称）
- 关键事实错误（参数、价格）
- 未经确认删除已确认内容
- **静默失败**（未标注却交付残缺结果）

■ 一张真实的评分卡 · T16「只改开头，卖点不许动」第 1 次执行

维度	得分	依据（评分人 A 的记录）
完成度	4	成片可导出，但未提供素材溯源
指令遵循	2	**卖点 2 与 3 被改写**，违反「卖点不许动」
内容质量	4	新开头的钩子更强，节奏更紧凑
稳定性	3	3 次中 2 次越界、1 次正确
可控性	2	需第 2 次强调「别改卖点」才改对
效率	4	6 步，与基准一致

WEIGHTED SCORE **3.10**

判定：FAIL　虽然总分高于 3.0，但**指令遵循 2 分 < 3.0**，触发第 ② 条。这正是设置多条件通过线的意义：**短板不能被其他维度补平**。

这条评分卡后来直接变成了 **P.21 的失败复盘** 与 **P.22 的头号优化项**。

总体 · 57 / 72 通过

79.2%

任务完成率。看起来还行，但**按类型拆开后，最差的一类只有 66.7%**
——而这一类恰好是最接近真实使用的一类。

加权总分

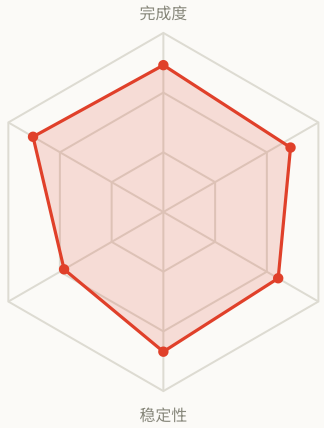
3.75 / 5

按任务类型 · 完成率（每类 18 次执行）

基础 · 单点能力	17/18	94.4%
复杂 · 多约束并存	15/18	83.3%
多轮 · 中途改需求	13/18	72.2%
异常 · 信息缺失 / 失败	12/18	66.7%

这条斜坡就是本项目的全部问题所在。 能力越"单点"，表现越好；越接近真实的连续使用，掉得越多。说明短板不在生成，**在状态管理与异常处理**。

六维得分



关键读数

完成度	4.1
指令遵循	3.6
内容质量	3.7
稳定性	3.9
可控性	3.2
效率	4.2

3 次全部通过的任务：**14 / 24**；结构一致率 86%
——**同一条任务跑 3 次，有 1 次会长得不一样**，这本身就是可用性风险。

三个值得写进周报的发现

① 掉分最狠的不是"做不出来"

是**"做出来了但不是我要的"**。15 次失败里，只有 1 次是完全没产出，其余 14 次都有可交付的东西，但违反了某条约束或改动了不该动的地方。

② 可控性 3.2 分，且与任务轮次强相关

第 1 轮平均 3.9，第 2 轮 3.3，第 3 轮 2.6。**每多一轮修改，可控性掉 0.6 分**——这说明状态没有在轮次之间被正确保留。

③ 异常场景的失败几乎都不是"能力不够"

T19–T24 的失败中，模型该做的其实都做了，问题是**没有"退一步"的路径**：没有降级目录、没有提问模板、没有部分交付。

这次评测的三个局限 · 写出来比藏起来有用

① 被测对象是原型，不是真实模型

所以结论只能用于判断**流程与机制是否成立**，不能用来评价任何模型。换成真实模型时，任务集与 Rubric 可以直接复用，分数必须重跑。

② 评分者只有 2 人，样本小

κ=0.71 只说明「趋势一致」，不能当作统计显著。要下结论至少需要 3 名评分者、每维 30 个样本。

③ 没有真实用户参与

「能交付」不等于「愿意用」。效率与确认次数是过程指标，真正的验证要看创作者的**二次编辑率**与**7 日复用**。

■ 失败分布 · 15 次失败按根因归类



■ 约束退化 5（33%） ■ 编辑越界 4（27%） ■ 降级缺失 4（27%） ■ 交互失当 2（13%）

CASE 01 · T16 — 3 次中 2 次失败

「只改开头」，卖点被一起改了

现象　用户说「开头改得更有冲击力」，Agent 重写了整段脚本：卖点 2「续航 14 小时」被改成「一天一充」，卖点 3 直接消失。

期望　只改 S2 开头钩子节点，S3 及之后的卖点文本保持逐字不变。

根因　修改指令没有绑定**编辑作用域**，规划层把它当成「重写脚本」重新规划了 S1，下游全部重算。

证据

trace t_8f3a：S1 regenerated，S3 dirty 标记但内容已变

修复　① 指令解析绑定节点 id；② S3 增加 `locked: must_mention`；③ QA 增加「未声明内容变化」比对。

回归用例

T16-a：改开头后卖点逐字一致率必须 = 100%

CASE 02 · T13 — 3 次中 1 次失败

改成 15 秒，但脚本没跟着变

现象　把 30s 改成 15s 后，时间线确实压到 15s，但**旁白还是 172 字**，语速被拉到 11 字/秒，听不清。

期望　时长变更应触发上游（脚本）重规划，而不是只压缩时间线。

根因　时长被当成**下游参数**而不是**全局约束**。约束没有反向传播到 S1。

证据

S1 status=clean，S6 时长 15.0s，QA 时长检查**通过**——检查器只查了总时长，没查语速

修复　① 时长变更标记 S1 dirty；② QA 增加「语速区间 4.0–5.5 字/秒」检查；③ 删减时让用户在「删卖点 / 缩解释」间选。

回归用例

T13-a：时长变更后语速必须在 4.0–5.5 字/秒

CASE 03 · T21 — 3 次中 2 次失败

素材找不到，整条流程停住

现象　指定素材不存在时，Agent 返回「任务失败」，前面 5 个节点的产出全部不可见。

期望　用替代素材或文字卡继续，交付时标注「1 处降级」。

根因　**没有降级目录**。工具只返回 error，规划层没有「出错之后还能做什么」的映射表。

证据

S4 `E_NO_MATCH` → 直接 abort，未尝试 fallback

修复　① 建立「失败码 → 降级动作」映射表；② 降级后必须写入交付清单；③ 失败不阻断其他分支（S5 继续跑）。

回归用例

T21-a：素材缺失时必须产出可交付结果 + 1 条降级说明

■ 三个案例的共同点

都不是「模型不会做」，而是**系统没有给"做错之后"留位置**：没有作用域、没有反向传播、没有降级目录。这三件事都属于机制设计，都可以在不换模型的前提下修好。

■ 我特意没做的事

没有把失败归因成「模型能力不足」然后结束讨论。归因到模型意味着**只能等下一版模型**；归因到机制，意味着**这一版就能改**。

■ 失败是怎么被记录下来的 · 执行日志字段（共 72 条，可逐条追溯）

字段	说明
run_id	任务 ID + 第几次执行，如 T16-r2
trace_id	贯穿整条链路的唯一标识，可定位到节点
node / tool	失败发生在哪个节点、调用了什么工具
error_code	5 类失败码之一，决定走哪条降级路径
scores[6]	六维得分 + 评分人 + 是否经过仲裁
note	评分依据原文，必须引用产出中的具体位置

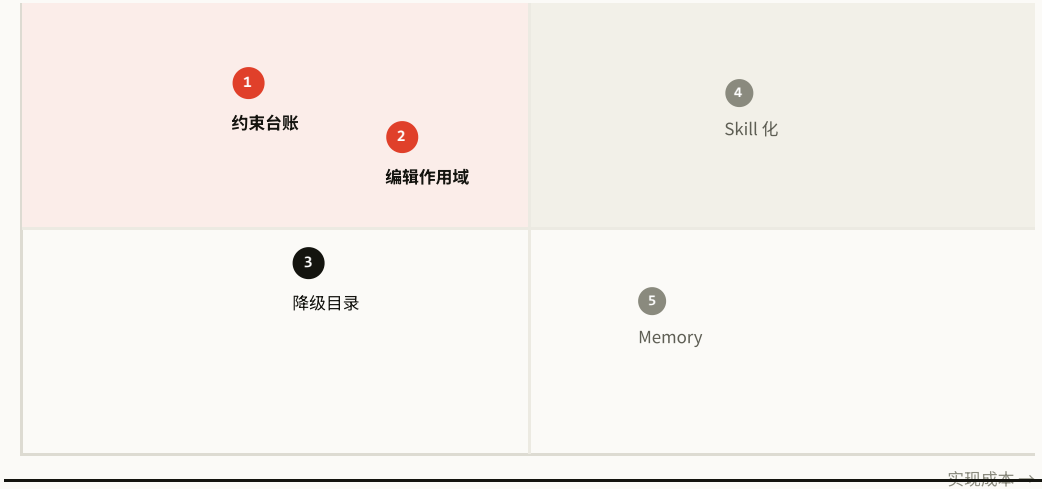
```
T16-r2 · trace t_8f3a
node=S1 → S3 dirty(unlocked)
tool=script.write  status=partial
error_code=E_SCOPE_LEAK
scores=[4,2,4,3,2,4]  weighted=3.10
verdict=FAIL（指令遵循 < 3.0）
note: 卖点2「续航14h」被改写为「一天一充」
```

字段设计的原则：**任何一条失败，都能被另一个人在不问我的情况下复现与复核。**

如果只能修三件事，
就是这三件。

排序依据不是「哪个分最低」，而是**影响任务数 × 严重度 ÷ 实现成本**。可控性分数最低，但它的成因分散在三个机制里，所以拆成了三项。

优先级矩阵 · 纵＝影响任务数　横＝实现成本



#	优化项	影响	成本	预期提分
1	**约束台账（Constraint Ledger）** 所有约束集中存储、每步校验、变更时反向传播	5 任务	中	+0.35
2	**编辑作用域（Edit Scope）** 指令绑定节点；未声明节点锁定 + 变更比对	4 任务	中	+0.28
3	**降级目录（Fallback Catalog）** 失败码 → 可执行替代动作，且必须写入交付清单	4 任务	低	+0.22
4	**Skill 化** 先把稳定流程沉淀，前提是上面三项已达标	–	高	下一版
5	**Memory** 没有可靠的编辑记录，记忆只会学到噪声	–	高	下一版

三件事分别改什么、改哪里、怎么验证

#	优化项	改什么（具体到机制）	改在架构的哪一层	怎么验证
1	**约束台账**	把 7 显式 + 4 隐含约束存成结构化 ledger，每个节点执行前注入、执行后回查；任一约束变更触发下游 dirty 标记	L2 规划层输入 L4 校验层	T13/T14/T17 回归 + 约束满足率 ⩾98%
2	**编辑作用域**	意图层输出必须带 node_id 与 scope；未声明节点加锁；改动前后生成 diff，越界即打回	L1 意图层输出 L5 交互层 diff	T16-a 卖点逐字一致率 = 100%
3	**降级目录**	5 类失败码 × 3 级降级动作的映射表；降级必须写入交付清单，不允许静默	L3 能力层 L5 交付清单	T21-a / T22-a 可交付率 = 100%

V0.2 目标

79.2% → 88%

多轮 72%→85%，异常 67%→83%。这两个数不动，其他优化都不算成功。

怎么验证真的变好了

同一套 24 条任务、同一套 Rubric、同样的重复次数，只替换被测版本。三个回归用例（T16-a / T13-a / T21-a）必须**连续 3 次全过**。

最重要的一句

评测的终点不是一份报告，是**一个被改过的版本**。如果三个月后指标没动，这份报告就只是一次练习。

不比宣传页，
比同一句话在三个产品里被怎么处理。

竞品分析的常见失败是「功能清单对比」：三家都有「AI 生成」，于是结论是「同质化」。 但真正的差异在**用户说第二句话之后**——那时产品才暴露它的架构假设。

■ 三个被测对象

产品	形态	为什么选它
剪映 · AI 成片	移动端 / 桌面端	最主流的「图文→成片」路径，用户基数最大，是基准线
Pippit	Web（海外）	明确的 Agent 化营销视频工具：表单输入、批量产出、品牌资产
即梦 AI	Web / App	生成能力最强的一档，用来看「纯生成路线」的边界

体验时间 2026 年 10 月，均为公开版本。产品迭代快，**具体路径会变，但下面指出的结构性断点不会因为改版消失**——它们来自架构，不来自 UI。

■ 统一任务 · 5 个任务覆盖一次完整创作

#	任务	看什么
1	把一段口语需求变成短视频脚本	需求理解深度
2	把脚本拆成分镜与素材需求	中间产物是否可见
3	改受众或风格后重新规划	是重跑还是重算
4	对结果提出局部修改（只改第 3 个镜头）	**编辑作用域**
5	检查并交付最终结果	交付完整度

■ 记录的字段 · 每个任务都填同一张表

- 操作步数
- 是否需要手动补救
- 失败点与提示文案
- 是否保留未完成项
- 总耗时（秒）
- 是否可回到上一步
- 产出是否可编辑
- 二次修改的成本

■ 方法上的自我约束

① **只用免费额度内的能力**，不氪金解锁，保证三家可比。

② **同一段原始文案**，不针对各家改写提示词——差异要来自产品，不来自我的提示技巧。

③ **每个任务跑 2 次**，第一次熟悉路径不计时，第二次记录。

■ 这份分析的局限

样本为 1 人单机体验，不代表大众用户；只测了中文场景；未覆盖付费档位与团队协作功能。 因此下面的结论只用于**提出假设**，不用于下判断——真正的结论要靠 A/B 与埋点。

03 八维能力矩阵 / CAPABILITY MATRIX

● 具备且好用　◐ 部分具备　○ 不具备
评分依据：P.23 的统一任务实测

能力维度	剪映 · AI 成片	PIPPIT	即梦 AI	判断依据（来自实测，不是功能列表）
1 任务理解	◐	◐	○	剪映能接住"文案+音色+模板"，但"18–25 岁、开头要抓人"这类约束不进系统；Pippit 用表单替代理解；即梦只接提示词
2 计划可见性	○	◐	○	三家都不展示"打算怎么做"。Pippit 的表单步骤最接近计划，但它是**输入表单**而非**执行计划**
3 生成质量	◐	◐	●	即梦的画面质感明显领先；剪映胜在配音与节奏的自然度；Pippit 偏模板化
4 编辑可控	◐	○	○	剪映有完整时间线，**但"改"是手动操作，不是 Agent 行为**；另两家只能整条重生成或换模板
5 交付完整	◐	●	○	Pippit 直接给可投放的成片+文案组合，交付目标最清晰；剪映给工程但无素材溯源；即梦只给视频文件
6 异常处理	○	○	○	**三家全部缺失**：生成失败即重来，没有降级、没有部分交付、没有"哪里坏了"的说明
7 记忆与个性化	○	◐	○	Pippit 有品牌资产（Logo、色板、口吻），属于**团队级记忆**；个体偏好三家都不记
8 协作与版本	◐	●	○	Pippit 面向营销团队，天然带多版本产出与品牌一致性；剪映靠工程文件传递

■ 矩阵读出来的三件事

① 第 4 列（编辑可控）是整条赛道的洼地。三家在"生成"上各有强弱，但在"改"上几乎是同一水平：要么手动，要么重来。这不是巧合，是因为**「改」需要架构支持**，不是加个按钮就行。

② 第 6 行（异常处理）全员为零。说明现在还是"能力竞争"阶段，没进入"可靠性竞争"阶段。谁先做，谁就先拿到"敢用"的用户。

③ 剪映的优势是它已经拥有"修改的界面"（时间线）。它缺的不是编辑器，是**把编辑动作翻译成 Agent 可执行指令的那一层**。

一个反直觉的观察

生成质量最好的产品（即梦），在 5 个任务里的**完成率反而最低**—— 因为它把"做得好不好"交给了用户判断，而不是自己检查。

质量高 ≠ 任务完成。

■ 任务 4「只改第 3 个镜头」的实测记录 · 单次体验，只看量级

产品	操作步数	耗时	是否需重新生成	可否撤销	最终结果
剪映 · AI 成片	9 步	3′20″	否（手动改时间线）	部分（Cmd+Z 可退）	改对了，但要自己找镜头、重对齐字幕
Pippit	3 步	1′05″	是（换模板重出）	否	整条重出，前后两条在节奏上不一致
即梦 AI	2 步	2′40″	是（整条重生）	否	重生成后其他镜头也变了，需要重新挑

三家的**步数差异不重要**，重要的是：**没有一个产品把"改一个镜头"当成一次可寻址的操作**。剪映是"人改机器产物"，另两家是"重掷一次骰子"。

剪映 · AI 成片 · 从一句话到可发布

STEP 01	STEP 02	STEP 03 · 断点 B1	STEP 04	STEP 05
输入文案 / 选音色	**生成粗剪时间线**	**手动改第 3 个镜头**	**检查时长 / 字幕**	**导出**
把口播稿贴进去，选音色与模板	旁白、字幕、配图自动落到轨道	在时间线上找到它、替换素材、重录音、对齐字幕——**4 个手动动作**	靠眼睛看，没有系统级检查清单	无素材来源记录，无未完成项提示

断点 B1 · 修改没有语义

用户想表达的是「把这个镜头的画面换掉」，但产品只提供「切割、删除、拖入、对齐」这组**操作级动词**。 用户的意图与产品的语言之间，缺一层翻译。

断点 B2 · 风格变更 = 重新开始

换成"更活泼"的调性，只能改模板或重新生成，**已经调好的 8 个镜头全部作废**。风格没有被参数化，所以无法只换"风格层"。

PIPPIT · 表单式路径 · 断点在哪

填品牌与卖点	选模板与时长	批量生成多条 → 选一条（B4）	下载 / 投放
表单化，理解成本最低	模板决定风格上限	选择成本转移给用户，但没有"为什么这条更好"的解释	交付即成品，不可编辑（B5）

把三家放在一起，断点其实只有三个

B1 修改没有语义（剪映）、**B2 风格无法单独替换**（三家）、**B3 交付不可编辑或不可溯源**（Pippit / 即梦）。 其余问题都是这三个的派生。

断点背后的同一个假设

三家都默认「生成是一次性的，修改是人的事」。 这个假设在 2023 年成立，在 Agent 能读写中间产物的今天已经不成立了。

完成同一创作任务的总成本（含返工）



时间不是重点，**时间花在哪**才是。剪映的 8 分 40 秒里，有 5 分 10 秒花在「找位置、对齐、重录」——全是断点 B1 的代价。

如果 B1 被修好，这一步会变成什么

维度	现在	修好之后
表达方式	切割 / 删除 / 拖入 / 对齐	「第 3 个镜头换成户外场景，别动配音」
动作数	4 步起	1 句指令
耗时	3′20″	≈40″
可否撤销	逐步撤销，容易错位	一次回滚到改动前
副作用	字幕需重新对齐	锁定其他轨道，无副作用

每个机会点都绑定证据、路径与验证指标
不是「建议做 AI」，是「建议改这一层」

OPPORTUNITY 01 优先级 高

把「计划」做进 AI 成片

证据 矩阵第 2 行三家全为 ○ / ◐；B1 断点显示用户在生成后立刻进入"手动找位置"的状态。

用户价值 生成完先看到「做了什么、按什么顺序、哪一步可能有问题」，把返工从"发现错误"提前到"预判错误"。

实现路径 不改生成模型：在粗剪产出后，把时间线反解成 6 个节点的计划视图，允许用户点节点定位到轨道。

风险 计划视图做成"技术日志"，用户不看。必须用创作语言（"开头钩子/卖点/收尾"）而不是节点名。

验证指标
计划展开率 ⩾60%；展开用户的二次编辑步数 −20%

OPPORTUNITY 02 优先级 高

让「只改一个镜头」成为一等公民

证据 B1：改一个镜头需要 4 个手动动作；第 4 行编辑可控三家最高只有 ◐。

用户价值 把"改一处"的成本从分钟级降到秒级，直接改善最痛的返工环节。

实现路径 在时间线上选中片段 → 自然语言描述修改 → 只重跑该片段的素材/配音/字幕 → 其余轨道锁定。

风险 片段与文案、字幕存在耦合，重跑一处可能破坏节奏。必须配"改动前后 diff"与一键撤销。

验证指标
局部修改成功率 ⩾90%；单次修改耗时 −50%

OPPORTUNITY 03 优先级 中

把「风格」从模板变成偏好约束

证据 B2：换风格要重新生成；矩阵第 7 行个体偏好三家全为 ○，Pippit 的记忆只到品牌级。

用户价值 不用每次重讲"我要克制、少形容词、节奏快一点"——这是创作者最高频的重复劳动。

实现路径 把风格拆成可调参数（语速、句长、形容词密度、BGM 能量），存成可见的"我的风格"，作为约束默认值。

风险 记忆会变成"自作主张"。必须可见、可编辑、可一键关闭，且写入需多次证据。

验证指标
重复描述次数 −50%；风格记忆关闭率 <15%

■ 三个机会点的共同前提

它们都不需要更强的生成模型，只需要**把「创作过程」变成可寻址的结构**：有节点、有节点 id、有输入输出。一旦有了这个结构，计划视图、局部重跑、风格参数化都是它的自然产物。

■ 如果只能推一个

推 02。因为它**可独立验证、不依赖新模型、且有明确的对立假设**：如果用户其实更愿意"整条重生成"，那 02 的假设就被推翻了——这是一个能被证伪的机会点，比"提升体验"有用得多。

■ 三个机会点的评估 · 用同一把尺子量

#	机会点	用户价值	实现成本	主要依赖	可证伪性	建议
01	**把「计划」做进 AI 成片**	中高	低	设计 + 前端，无需模型改动	强	先做，成本最低的差异点
02	**只改一个镜头**	高	中	剪辑引擎需支持片段级重跑	强	**主推**，直击最痛的返工
03	**风格变成偏好约束**	中	中高	需要风格参数化 + 记忆机制	中	放 V1.0，等前两项稳定

WEEK 1
埋点现状：一次修改的步数、耗时、放弃率。先拿到基线，否则后面无法证明变好。

WEEK 2
做最小可点版本：选中片段 → 一句指令 → 只换该片段。不做计划面板。

WEEK 3
灰度 5%：重点看「改完之后有没有再手动调」——这是它到底有没有省事的唯一证据。

WEEK 4
决策：局部修改成功率 <70% 就停下，先修片段级重跑的稳定性，不扩功能。

附件 feedback-50.csv
全部为自建模拟数据

反馈不是用来「统计满意度」的，是用来定位机制的。

这 50 条是我按真实创作者语气逐条写的**模拟数据**——目的不是证明"用户想要什么"，而是练习**从一句抱怨走到一个机制问题**的推理过程。

■ 字段设计 · 10 个字段，前 5 个是事实，后 5 个是判断

字段	取值 / 说明
fb_id	F-001 ~ F-050
user_type	A 效率型 / B 成长型 / C 团队型（对应 P.06 画像）
scene	首次创作 / 二次修改 / 复用模板 / 异常中断
raw_text	用户原话，保留口语、情绪与错别字
category	C1–C6 六类（见右侧分布）
severity	严重 / 中 / 轻（是否导致放弃或重做）
frequency	高频 / 偶发 / 单次
root_cause	归因到机制层，不写"模型不行"
suggestion	可执行的优化建议（动词开头）
priority	P0 / P1 / P2（依据见 P.28）

为什么后 5 个字段是"判断"而不是"事实"：
原始反馈只有一句话，分类、严重度、根因都是**我的解释**。把它们和事实字段分开，才能被别人质疑和推翻——这比"数据看起来很完整"重要。

■ 分布 · 类型 × 问题分类（共 50 条）

问题分类	A	B	C	合计	其中"严重"
C1 局部修改与作用域	4	8	2	**14**	6
C2 约束保持	5	5	1	**11**	4
C3 过程可见性	3	4	2	**9**	1
C4 素材匹配	4	2	1	**7**	1
C5 字幕与配音	3	1	1	**5**	0
C6 记忆与个性化	0	3	1	**4**	0
合计	19	23	8	**50**	12

C1 与 C2 占 50%（25 条），且"严重"占比最高——与 P.07 的痛点排序、P.18 的评测失败分布**三处互相印证**。

■ 三条原始反馈（保留口语）

F-014 · B · 二次修改 · 严重
「改了开头之后，原来那句『续航 14 小时』被它改成『一天一充』了，这不是给我埋雷吗，我根本没让它动这句。」

F-031 · A · 异常中断 · 严重
「做到一半就一个『生成失败』，我前面选的素材、写的文案全没了，只能从头再来一遍，第二次还是错在同一个地方。」

F-042 · B · 复用模板 · 中
「每次都要说一遍『别太夸张、少堆形容词』，说了七八次了它还是不记，我怎么感觉每次都像第一次用。」

■ 如果这是真实数据，我会从哪四个渠道采 · 以及每个渠道的偏差

应用内一句话反馈

完成或放弃瞬间的情绪，量最大。
偏差：只有受挫或特别满意的人会填。

社区帖与评论区

完整场景与替代方案（用户拿什么绕过去）。
偏差：重度用户声音过大。

客服工单

明确的故障与损失，可信度最高。
偏差：只覆盖知道找客服的人。

行为埋点

真实失败率：改了几次、在哪放弃。
偏差：知道"发生了什么"，不知"为什么"。

方法论：**语音类反馈看"为什么"，埋点看"有多少"**。只用一种都会得出片面结论——所以 P.20 的评测同时用了自动检查和人工评分。

5 WHYS · 以 F-014 为例，追问到"能被改的那一层"

为什么卖点被改了？ 因为"改开头"被理解成"重写脚本"。

为什么理解成重写？ 因为指令没有绑定节点，也没有声明"只改哪里"。

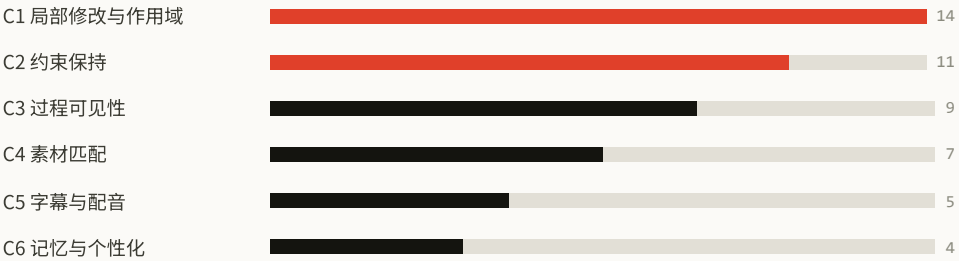
为什么没有绑定？ 因为计划里的节点只有"依赖"，没有"可写范围"。

为什么只有依赖？ 因为 Schema 把节点当成"执行步骤"，而不是"数据对象"。

根因：计划对象缺少「写权限」概念。
scope 不是执行属性，是**数据属性**——它必须写进 Schema，而不是靠提示词约束。

归因的验收标准：追到"能写进产品文档的那一层"就停。 如果结论是"模型理解能力不足"，说明还没追到底——那不是一个能在两周内被改的东西。

分类分布（按"严重条数 × 频次"加权）



注意 C6 只有 4 条，但它在 P.07 的痛点表里排第 7——**两个来源都指向"先别做记忆"**。 这条一致性比任何单个数字都更有说服力。

需求池 TOP 6 · RICE 排序（REACH=受影响反馈数，IMPACT=1–3，CONFIDENCE=0.5/0.8/1，EFFORT=人日）

#	需求	一句话说明（动词开头）	R	I	C	E	RICE	优先级
1	**编辑作用域**	把修改指令绑定到节点，未声明节点加锁并在改动后比对	14	3	1	2	**21.0**	P0
2	**约束台账**	把约束集中存储并在每次节点执行前后校验，变更时反向传播	11	3	0.8	2	**13.2**	P0
3	**断点可恢复**	失败后保留已完成节点，支持从断点继续而非全量重跑	9	3	0.8	3	**7.2**	P1
4	**计划摘要**	生成前给出 3 行计划摘要，可展开看细节	9	2	1	1	**18.0**	P1
5	**素材替代策略**	建立"低匹配 → 替代素材 → 文字卡"的降级链并写入清单	7	2	0.8	2	**5.6**	P1
6	**偏好记忆**	写入需 2 次证据，读取可见可删，可一键关闭	4	2	0.5	4	**1.0**	P2

第 4 行（计划摘要）RICE 高于第 3 行，但优先级排在后面——因为**它是 E1 实验的变量，不是立刻要上线的功能**。 RICE 给排序，实验给决策，两者不该混为一谈。

收敛过程 · 50 条怎么变成 6 条

50 原始反馈 → **23** 去重后 → **11** 问题簇 → **6** 需求

去重不是"删掉重复的"，而是**合并成同一个机制问题**。 23 条去重后只剩 11 个簇，说明 50 条里有一半在说同样的三件事——这本身就是结论。

明确不做的三条 · 以及为什么

「一键发全网」 属于分发链路，不在创作体验的范围内，接第三方更划算。

「模板不够多」 这是内容供给问题，运营手段解决，不是产品机制。

「免费额度太少」 商业策略问题；把它当产品问题会让优先级失真。

一个好的实验，
在开始之前就知道什么情况下要认输。

两个实验对应需求池的 P0 与 P2：一个验证"计划可见"是否真的降低返工，一个验证"记忆"是否真的减少重复劳动——后者我预期会被推翻。

E1 · 计划摘要卡

对应 P0 需求 4

假设：在生成前展示 3 行计划摘要（做什么 / 几步 / 多久），能让用户在启动前发现问题，从而**降低首次交付的返工率**。

组别	处理
A 对照组	现状：点击「生成」直接开始，无摘要
B 摘要	展示 3 行摘要，可展开看 6 个节点，不可编辑
C 摘要+可编辑	同 B，且可删除/调整节点顺序

主指标	**首次交付通过率** = 生成后未做任何修改即导出的会话 ÷ 总会话
次指标	摘要展开率、平均修改轮次、生成启动率
护栏指标	生成启动率跌幅 ≤2pp；启动到出片时长增幅 ≤3s（不能为了展示而变慢）
样本 / 周期	每组 8,000 会话，灰度 5%，2 周（首周看趋势，次周看稳定性）

决策规则（事先写好）

主指标 **+3pp 且护栏不破** → 全量；**+1~3pp** → 延长 1 周补样本；**<+1pp** → 停，转向 E1'（把摘要做成"生成后可回溯"而非"生成前必看"）。

E2 · 偏好预填

对应 P2 需求 6

假设：基于最近 3 次同类创作自动预填风格参数（语速/句长/形容词密度），能**减少用户重复描述的时间**，且不会被感知为"自作主张"。

组别	处理
A 对照组	现状：每次从默认风格开始
B 静默预填	自动带上上次偏好，不提示
C 显式预填	自动带上，并提示「我记住了你偏好克制风格 · 修改 / 关闭」

主指标	**需求描述字数与耗时**（从打开到点击生成）
次指标	预填参数修改率、记忆关闭率、二次创作率
护栏指标	**关闭率 >20% 立即停**——超过这个数就不是"贴心"，是"越权"
样本 / 周期	每组 5,000 会话，3 周（需覆盖至少 3 次创作行为才能形成偏好）

我的预判（写在这里以便被打脸）

B 组（静默预填）很可能**主指标更好看但关闭率极高**；真正该上的可能是 C。如果 B 与 C 差异不显著，说明用户根本不在意"是否被告知"——那我的整个 Memory 设计前提就要重写。

共同约束：必须能"不伤用户"地失败（灰度 5%、可一键回滚、异常自动熔断）· 必须有护栏指标 · 决策规则必须事先写定

实验的目的不是证明我的方案对，而是给团队一个可复用的判定框架：什么改动值得全量，什么该被砍掉。

■ 指标口径与埋点 · 不写清楚，实验就变成各说各话

指标	口径（一句话算得出来）	埋点位置	谁来读
首次交付通过率	生成完成后未做任何编辑即点击导出的会话 ÷ 生成完成会话	生成完成事件 + 导出事件 + 编辑事件	产品 / 数据
平均修改轮次	一次创作中"修改并重新生成"的次数，按会话去重取均值	节点重跑事件	产品
计划展开率	点击"展开计划"的会话 ÷ 看到计划入口的会话	交互埋点	设计
记忆关闭率	关闭"个性偏好"的用户数 ÷ 触发过预填的用户数	设置页 + 结果页"别再这样"	产品 / 策略

依赖与排期：E1 前置是计划摘要组件（约 2 人日）；E2 前置是偏好存储与设置页（约 5 人日）。**两者不能并行**——都改生成入口，会互相污染实验组。先做 E1，因为它的结果决定 E2 值不值得做。

Skill 不是「提示词模板」，是带校验的流程封装。

提示词模板只解决"怎么说"，Skill 要解决的是"按什么顺序做、每步怎么判合格、不合格怎么办"。 它必须能被**引用、组合、评测、版本化**——否则只是把 prompt 换了个地方存。

■ 三者的区别（很容易混）

形态	解决什么	能否被评测
Prompt	一次对话里怎么说	难（无稳定输入输出）
Tool	一个原子能力（生成/检索）	能（有契约）
Skill	一串工具 + 判断 + 兜底的组合	**能，且必须能**

■ 为什么 SKILL 必须带 EVAL

技能一旦被复用，它的错误也会被**批量复制**。所以每个 Skill 上线前必须绑定一组 benchmark 子集：`T07 / T10 / T16` 全过才允许发布新版本； 版本回滚的成本必须低于修复的成本。

■ 技能定义 · SHORTFORM.PRODUCT_RECOMMEND V1.2

```
# 一个技能 = 意图 + 参数 + 步骤 + 校验 + 兜底
id: shortform.product_recommend    version: 1.2.0
intent: 给定产品与卖点，产出 30±2s 竖屏种草视频

params:
  product:        {type: object, required: true}
  selling_points: {type: array,  min: 1, max: 6}
  audience:       {enum: [18-25, 25-35, 35-45], default: 18-25}
  tone:           {enum: [克制, 热情, 专业], default: 克制}

steps:
  - id: hook       # 开头钩子
    do:    生成 3 个前 3 秒钩子（反差 / 提问 / 数字）
    check: 每个 ≤3s，且不含极限词
  - id: body       # 主体论证
    do:    按卖点排序写 4 句，每句 ≤18 字
    check: 卖点覆盖 100%，总字数 120-170
  - id: shotlist   # 分镜：每句 1-2 个镜头，标注景别与情绪
    check: 镜头/句 ≤2，无连续同景别
  - id: assettize  # 素材：匹配分 <0.5 走降级，须带授权类型
  - id: assemble   # 合成：配音 + 字幕 + 粗剪
    check: 时长 29-31s，语速 4.0-5.5 字/秒

outputs: [script, shotlist, captions, timeline]
guards: 禁词命中 → 中止转人工(R3) | 任一步失败 → 按降级目录处理并写入清单
eval:   on [T07, T10, T16]，三条不过不允许发版
```

■ SKILL HUB 的四条设计原则 · 决定这个生态能不能长大

① 可发现

用户说需求，系统匹配技能，而不是让用户逛"技能商店"。**用意图检索，不用分类目录。**

② 可组合

上一个技能的输出能直接作为下一个的输入。否则技能越多，用户越难用。

③ 可评测

每个技能绑定 benchmark 子集与通过线。没有评测的技能不允许进入推荐位。

④ 可版本化

语义化版本 + 灰度 + 一键回滚。技能是会被依赖的，改动必须向后兼容。

■ 一个判断：SKILL 的护城河不是数量，是「复用率 × 通过率」

100 个没人用的技能不如 5 个被反复用且稳定的技能。所以 Skill Hub 的核心指标不该是"技能数"， 而是**复用率**（同技能被 ≥3 次使用的用户占比）与**通过率**（用该技能完成的任务占比）。

风险：技能会僵化创作。如果所有用户都用同一个"爆款结构"，内容会趋同—— 所以技能应该封装**流程**，而不是封装**风格**。

记忆的价值不是「记得多」，是少问一次，且不问错。

记错了比不记更糟：用户要花精力去纠正，还得重新建立信任。所以这套设计的重心在**写入门槛**与**纠错成本**，不在"能记多少"。

三层记忆 · 生命周期完全不同

层级	记什么	写入触发	生命周期	用户可见性
会话态	当前任务的约束、已确认项、未完成项	自动，随对话产生	任务结束即销毁	全程可见（就是计划面板）
项目态	这条视频的素材、版本、修改历史	自动，随项目创建	30 天无访问则归档	可查、可回溯、可删除
个体态	风格偏好、禁用词、常用结构、受众画像	**需 2 次证据**或显式告知	180 天衰减，可续期	设置页可查看 / 编辑 / 关闭

三层分开的意义：**会话态解决"这次别忘"，个体态解决"下次别问"**。混在一起就会出现"我随口说的一句话被记了半年"。

写入规则 · 四道闸门

① 显式 > 隐式 用户说「记住我喜欢克制风格」→ 直接写；从行为推断 → 需 2 次同类证据。

② 只记"稳定的偏好" 一次性的临时要求（"这次短一点"）不进个体态，留在会话态。

③ 冲突以"最近 + 显式"优先 但旧值不删除，转为历史，避免"改回来"时又从零开始。

④ 敏感信息一律不写 价格、客户名单、未公开产品信息，即使被提到也不落库。

读取 · 不是"全带上"，是"挑 3 条"

检索与注入

1. 按当前任务意图检索候选记忆
2. 用「相关度 × 最近使用 × 置信度」排序
3. **只注入 Top 3**，其余按需展开
4. 注入时标注来源：「根据你过去 3 次的选择」

为什么要限量：记忆越多，越容易和当前指令冲突，模型也越容易"抓着旧偏好不放"。

一个具体例子 · 记忆怎么被用起来

用户第 4 次做数码视频，输入一句话。系统检测到个体态里有 「偏好克制」「句长 ≤18 字」「常用结构：钩子→参数→对比→结论」，自动预填为约束默认值， 并在输入框下方显示：**「已按你的习惯预填 3 项 · 修改」**。 用户可以直接生成，也可以改——**默认值是可以被推翻的，这是信任的前提。**

失败模式 · 记忆会怎么坏

记忆污染	把一次性要求记成长期偏好 → 用"2 次证据"门槛挡住
过度个性化	永远只给同一类结果，创作失去探索 → 保留 10% 随机变体
纠错成本高	用户不知道怎么删 → 设置页 + 结果页都能一键"别再这样"
隐私越界	跨账号复用偏好 → 记忆严格绑定账号，不做跨端合并

为什么我把 MEMORY 排在 V1.0 而不是更早

因为记忆依赖两个前提：**可靠的编辑记录**（知道用户改了什么）与**稳定的约束体系**（知道该记哪几个维度）。这两件事在 V0.5 之前都不成立——那时候记下来的都是噪声。

衡量记忆是否"有用"的唯一标准

不是"记住了多少条"，而是**用户的描述字数有没有变少、关闭率有没有上升**。 这两个数一个降一个不涨，才说明记忆在做正功。

关于创作者 Agent，我现在的五条判断。

它们都不"正确"，只是我做完这一轮研究与设计后愿意为之负责的立场。 如果你不同意其中任何一条，我很想听理由。

01

Agent 的护城河不在生成，在「改」的成本。

生成能力会被拉平，修改成本不会——它取决于架构里有没有"可寻址的中间产物"。这是产品决策，不是模型决策。

02

可控性是可以被设计出来的，不是靠模型变聪明。

计划可见 + 作用域明确 + 可回滚，这三件事今天就能做。做了之后，同一个模型的表现会立刻不一样。

03

确认不是越少越好，是「确认预算」要花在用户在意的地方。

一条视频最多打断 3 次，且只打断不可逆操作。第 4 次打断之后，确认就变成了盲点。

04

Skill 的竞争不是数量，是「谁的技能可被验证」。

评测即分发。没有 benchmark 的技能不该被推荐给用户——因为它的错误会被批量复制。

05

Memory 应该是「可见的、可删的、有证据的」。

记错了比不记更伤。个性化真正的指标不是记住多少条，而是用户少说了几句话、且没有被打扰。

这五条如果被数据推翻，我会改。但在被推翻之前，我愿意按它们做决策。

■ 为什么是剪映 · 以及我能补上的位置

我看到的剪映

它已经拥有三样别人没有的东西：**最大的创作者基数、最完整的编辑界面、从生成到分发的全链路**。 缺的不是能力，是把这些能力组织成"可被 Agent 操作"的结构。

我能补的位置

不是画新功能，而是做三件"翻译"： 把创作者的口语翻译成约束；把约束翻译成任务图；把任务图翻译成可以被评测的指标。 这正是这份作品集反复在做的事。

我入职后想先验证的三个问题

① 用户到底愿不愿意看"计划"，还是只想快点出片？ ② 「只改一个镜头」的真实需求频次有多高？ ③ 创作者对"AI 记住了我"是感到贴心，还是被冒犯？

■ 关于我 · ABOUT

13410164607 · 2901941647@qq.com · prototype.html

唐睿

2027 届 · 网络与新媒体

求职方向：AI 创作产品的策略与运营

网络与新媒体专业 2027 届本科生，具备 **AIGC 内容生产、短视频制作、互联网内容运营及 AI 创作工具**实践经验。

曾参与 **AI 漫剧内容制作**与互联网短视频视觉生产，熟悉从内容需求拆解、AI 素材生成、人工筛选到后期制作的创作流程。

持续关注大模型应用、AI 视频生成及创作工作流，具备从实际创作场景中**识别效率瓶颈、判断生成内容质量**并提出优化思路的能力。

具备产品化思维、跨领域学习能力及结构化表达意识，希望进一步探索 AI Agent 在内容创作、任务执行和个性化创作体验中的应用。